

품질 원인추적 AI Agent — 기술설명서

팀명 GPT 가 아니라던데요(김동환·김승록·유동현) · 대회 제 4 회 경남 AI·SW 경진대회 대학부 · 작성일 2026-10-05

공정 데이터와 작업표준서(SOP)는 시뮬레이션용 가상 자료다. 데이터·비전 모델·공정 시뮬레이션은 「기술설명서」에서 다루며, 이 문서는 Agent 의 구조와 동작만 설명한다.

1. Agent 개요

1.1 역할

비전 AI 의 결함 판정과 제품별 공정 이력을 결합해 원인을 스스로 조사하고, 작업표준서와 설비 허용범위 안에서 조정값을 근거와 함께 제안하는 품질 원인추적 Agent 다. Agent 는 조사와 제안까지만 하고, 설비 변경은 작업자가 승인한 뒤에만 이뤄진다.

1.2 동작 모드

Agent 는 시연 앱(app.py)의 원인 분석 대화로 동작한다. 작업자가 검출 보관함에서 불량 제품을 고르고 "이 제품 어느 공정에서 문제가 생겼어?", "어떻게 조치해야 해?"처럼 물으면, Agent 가 그 제품의 공정 이력과 최근 동향을 조사해 답한다. 사이드바에서 두 가지 모드 중 하나를 고른다.

모드	LLM	동작 방식	용도
로컬 LLM (기본)	Ollama · Qwen3 8B	근거 고정형: 엔진이 원인·조치를 계산하고 LLM 은 추가 조사와 설명 작성	시연·현장 배포 기준
오프라인	없음	규칙·통계 엔진만으로 답변	LLM 장애 시 Fallback

로컬 LLM 을 기본으로 택한 이유는 제조 현장의 공정 데이터가 외부 서버로 나가지 않아야 하기 때문이다. Ollama 는 공장 내부 PC 에서 모델을 실행하므로 인터넷 연결이나 외부 API 비용 없이 동작한다. 다만 8B 급 소형 모델은 숫자를 틀리게 옮기거나 근거 없는 조치를 지어낼 위험이 커서, 판단은 검증된 엔진에 맡기고 LLM 에는 설명만 맡기는 "근거 고정형" 구조를 설계했다(2 장).

이와 별도로 터미널용 조사 모드(run_demo.py)가 있다. "최근 불량률이 늘었다"는 목표만 주면 공장 전체를 대상으로 급증 탐지부터 승인 대기 등록까지 도구를 차례로 호출한다. 이번 개발에서는 규칙 기반 플래너(--offline)로 실행해 도구와 Feedback 동작을 검증했다(6.3 절).

1.3 Agent 6 요소 대응


요소	구현
Goal	작업자가 고른 불량 제품과 자연어 질문(원인·

요소	구현
	조치·이력)
Planning	질문 유형(원인·조치·이력·등록)을 판별해 조사 범위를 정하고, LLM은 부족한 근거를 채울 도구를 스스로 고름
Reasoning	이 제품의 공정값과 최근 300개 제품의 SHAP 순위를 함께 보고, 공정 원인인지 단발성·오검출인지 판단
Tool Use	도구 9종 (3장)
Memory	조치 제안과 승인·거절 결과를 actions 테이블에 저장, get_action_history로 이후 대화에서 참조
Feedback	조정값 검증 실패 시 안전값으로 재검증, LLM 답에 근거 없는 숫자가 있으면 폐기하고 엔진 결과 사용, LLM 호출 실패 시 오프라인 전환

2. Agent 구조

LLM은 설명만 말고, 원인과 조치는 검증된 엔진이 정한다

로컬 LLM(Ollama · Qwen3 8B) 근거 고정형 모드



로컬 LLM 근거 고정형 처리 흐름 · 4 단계

작업자가 질문하면 규칙·통계 엔진이 먼저 원인과 조치를 계산해 화면에 바로 보여준다. 그동안 LLM 이 필요한 도구로 추가 조사를 하고 작업자가 읽기 쉬운 설명을 쓴다. 설명에 근거에 없는 숫자가 있으면 LLM 답을 버리고 엔진 결과를 그대로 둔다. 어느 경우든 작업자가 보는 원인·조치 판단은 엔진이 계산하고 검증한 것이다.

2.1 LLM 계층

LLM 은 LangChain 의 ChatOllama(langchain-ollama)로 연결한다. 도구 함수는 StructuredTool 로 바꿔 bind_tools 로 붙이고, 도구 호출 반복(Agent 루프)은 직접 구현했다. 설정은 .env 의 LLM_PROVIDER=ollama, OLLAMA_MODEL=qwen3:8b 로 한다.

항목	설정
모델	qwen3:8b (Ollama)
실행 위치	공장 내부 PC (localhost:11434)
temperature	0
주요 설정	문맥 8,192 토큰, 출력 최대 700 토큰, 추론(think) 단계 끄, 모델 30 분 메모리 유지
도구 결과 전달	한 줄 요약만 전달

로컬 LLM 설정은 RTX 3060 급 GPU 에서 응답 시간을 줄이는 데 맞췄다. Qwen3 는 답하기 전에 긴 추론 과정을 생성하는데, 이를 끄고(reasoning=False, /no_think) 도구 결과도 요약만 넘겨 프롬프트를 짧게 유지한다.

사용한 로컬 모델은 Ollama 의 qwen3:8b(모델 ID 500a1f067a9f, 5.2GB)다. 같은 이름이라도 배포 시점에 따라 모델 파일이 바뀔 수 있으므로, 평가 결과를 재현할 때는 ollama list 로 이 ID 와 일치하는지 확인한다.

2.2 근거 고정형 처리 (로컬 LLM 모드)

- 엔진 계산:** 규칙·통계 엔진이 제품 역추적, SHAP 원인 순위, SOP 검색, 조정값 검증을 수행해 원인·조치를 계산하고, 그 결과(검증된 조언)를 즉시 화면에 표시한다.
- LLM 추가 조사:** LLM 이 질문을 보고 엔진 결과에 없는 근거가 필요하면 도구를 호출한다. 최대 2 단계이며, 승인 대기 등록 같은 쓰기 도구는 주지 않는다.
- LLM 설명 작성:** 엔진 결과와 추가 조사 결과만을 근거로 4~7 줄 설명을 쓴다. 새로운 사실·숫자·계산을 더하지 말라는 지시를 받는다(4.2 절).
- 근거 검사:** 코드가 LLM 설명을 다시 검사한다. 엔진 결과와 추가 조사 결과에 없는 숫자가 하나라도 있으면 LLM 답을 버리고 엔진 원문을 낸다(한 자리 정수와 제품 ID·시각은 제외). 원인·조정 답변에서 엔진이 찾은 이탈 변수를 LLM 이 빠뜨리면 엔진이 보충하고, 엔진이 조치를 내지 않았는데 LLM 이 지어낸 조치·권고 문장은 지운다.

이 구조의 핵심은 역할 분리다. 원인 판단과 조정값처럼 틀리면 위험한 일은 검증 가능한 코드가 맡고, 작업자가 이해하기 쉽게 풀어 쓰는 일과 추가 질문 대응은 LLM 이 맡는다. 또 엔진 결과를 먼저 보여주므로 LLM 응답이 느려도 작업자는 기다리지 않고 조언을 받는다.

2.3 오프라인 엔진과 Fallback

오프라인 모드는 2.2 절 1 단계의 엔진만으로 답한다. 로컬 LLM 모드에서 LLM 호출이 실패하면(Ollama 미실행, 모델 미설치 등) LLM 단계를 건너뛰고 엔진이 계산한 답을 그대로 보여주므로, 시연 중 LLM 에 문제가 생겨도 답변이 끊기지 않는다.

2.4 조사 기록

앱은 답변마다 호출된 도구와 결과 요약을 "엔진"과 "LLM" 중 누가 호출했는지와 함께 보여준다. 답변 아래에는 최종 답이 어떤 경로로 나왔는지(근거 검증 통과 / 엔진 원문 / 오프라인)가 표시되어, 작업자가 답의 근거를 확인할 수 있다. 터미널 조사 모드는 같은 내용을 logs/*.jsonl 에 경과 시간과 함께 남긴다.

3. 도구 9 종

도구는 모두 파이썬 함수이며 JSON 으로 바꿀 수 있는 결과를 돌려준다. 엔진과 LLM 이 같은 함수를 공유하므로 어느 모드든 수치와 검증 기준이 같다. 함수의 docstring 과 인자 타입이 그대로 LLM 에 전달되는 도구 설명이 되며, 소형 모델이 변수 이름을 틀리지 않도록 영문 변수 키 목록을 docstring 에 명시했다. 1 번은 대화 전용(agent/chat.py)이고 2~9 번은 공통(agent/tools.py)이다. 로컬 LLM 모드에서 LLM 에게는 9 번(등록)을 제외한 조회 도구만 준다.

#	도구	하는 일	주요 입력	핵심 로직
1	get_product_trace	선택한 제품이 각 공정을 지날 때의 값 역추적	제품 ID	공정별 통과 시각. 값을 정상범위와 비교, 결함 유형의 원인 후보 변수가 원인 방향으로 얼마나 치우쳤는지 계산
2	get_defect_summary	결함 급증 유형 탐지	최근 300 개, 기준 1,500 개	발생률이 기준의 2 배 이상(최소 1%) 이고 5 건 이상이면 급증
3	detect_deviation	공정변수 이탈 탐지	최근 300 개	변수별 평균 z-score, 정상범위 밖 비율 20% 이상이면 이탈
4	get_process_history	결함 제품과 정상 제품의 공정값 비교	결함 유형	제품 ID 로 결함 후 변수별 평균 차이를 표준편차

#	도구	하는 일	주요 입력	핵심 로직
				단위로 정렬
5	rank_causes	SHAP 원인 순위	결함 유형	Gradient Boosting 분류기 학습 후 결함 확률을 올린 SHAP 기여만 집계, 표본 10 건 미만이면 신뢰도 낮음 반환
6	search_sop	작업표준서 검색 (RAG)	검색어	SOP 를 섹션 단위로 나눠 문자 n-gram TF-IDF 코사인 유사도로 상위 3 개 반환
7	check_adjustment	조정값 검증	변수, 제안값	조정 가능 여부, 허용 한계, 1 회 최대 조정폭, 정상범위를 검사하고 위반 시 안전값 제시
8	get_action_history	과거 조치 이력 조회 (Memory)	결함 유형, 변수	actions 테이블에서 최근 조치와 승인·거절 상태 조회
9	submit_recommendation	조치 제안을 승인 대기로 등록	결함 유형, 변수, 값, 사유	내부에서 check_adjustment 를 다시 실행해 통과한 경우에만 pending 상태로 저장

3.1 조정값 검증 상세

check_adjustment 는 Agent 가 설비에 영향을 줄 수 있는 유일한 경로를 지키는 도구라 검사 순서를 고정했다.

1. 조정 불가 변수(제강의 개재물 지수)면 즉시 실패하고 "제강 공정 통보 필요"를 돌려준다.
2. 제안값이 설비 허용 한계를 벗어나면 한계값으로 자른다.
3. 현재값(최근 30 개 평균)과의 차이가 1 회 최대 조정폭을 넘으면, 현재값에서 조정폭만큼만 움직인 값을 안전값으로 제시한다.
4. 조정 후 값이 정상범위 밖이면 "추가 단계 조정 필요"로 표시한다.

하나라도 걸리면 ok=false와 함께 위반 내용과 안전값을 돌려준다. 프롬프트 규칙에 따라 LLM은 안전값으로 다시 검증한 뒤 그 값을 써야 한다.

3.2 SOP 검색

작업표준서(agent/sop/열연_품질_작업표준서.md)는 공통 원칙과 결함 6 종별 대응, 압하력 관리의 8개 섹션으로 구성된 가상 문서다. 한국어 띄어쓰기 차이에 강하도록 단어 대신 2~4 글자 문자 조각(n-gram)으로 색인한다. 문서가 늘어나면 같은 search(query, k) 인터페이스를 유지한 채 임베딩 기반 벡터 검색으로 교체할 수 있다.

4. 판단 규칙

4.1 엔진의 판단 규칙

로컬 LLM 모드와 오프라인 모드에서 원인·조치를 정하는 것은 규칙·통계 엔진이다(_chat_offline). 작업자가 고른 제품의 검출 시점을 "현재"로 두고, 그 이전 데이터만으로 판단한다.

- 질문 판별:** 질문의 낱말로 원인·조치·이력·등록 중 무엇을 묻는지 정한다. 어느 것도 아니면 원인 질문으로 본다.
- 원인:** 이 제품이 각 공정을 지날 때 정상범위를 벗어난 값을 먼저 확인하고, 최근 같은 결함의 SHAP 원인 순위(1~2 순위)와 함께 제시한다. SHAP 학습 구간(최근 최대 2,000 개)에 같은 결함이 10 건 미만이거나 최근 구간에 없으면, SHAP 대신 공정 사양에 정의한 결함-원인 매핑(작업표준서와 같은 내용)과 이 제품의 값으로 추정하고 단발성일 수 있다고 밝힌다.
- 단발성·오검출 판단:** 원인 후보 변수가 이 제품에서도, 최근 구간에서도 정상범위 안($|z| < 2$)이면 공정 원인으로 단정하지 않는다. 이 제품에 이탈 값도 없으면 원인 답변에서 단발성으로 판단하고, 이때 검출 신뢰도가 0.5 미만이면 오검출 가능성을 알리며 육안 재검사를 권고한다.
- 조치:** 원인 변수가 조정 불가(개재물 지수)면 해당 LOT 보류와 제강 통보를 제안한다. 조정 가능하면 SOP를 검색하고, 목표값(공정 평균)을 검증해 실패하면 안전값으로 다시 검증한 값을 제안한다. 다만 다음 경우에는 조정하지 않고 관찰을 권고한다. ① 단발성으로 판단한 경우 ② 라인의 최근 평균(최근 30 개)이 목표에서 1.5σ 안이라 설정을 바꿀 근거가 약한 경우 ③ 라인의 최근 평균이 이미 원인 반대 방향으로 목표를 넘어 회복된 경우.
- 등록:** 작업자가 등록·승인을 요청할 때만 승인 대기로 등록한다.
- 이력:** 같은 결함의 과거 조치와 승인·거절 상태를 보여준다.
- 참고:** 이 제품에서 정상범위를 벗어났지만 이번 결함의 원인 변수가 아닌 값은 원인으로 섞지 않고, 다른 결함의 원인 변수라면 그 결함의 전조로 지켜보라고 따로 알린다.

4.2 LLM 설명 규칙

로컬 LLM은 엔진 결과를 작업자가 읽기 쉬운 문장으로 옮기는 역할만 받는다. 설명 프롬프트(NARRATE)의 핵심 규칙은 다음과 같다.

규칙	막으려는 문제
분석 결과에 없는 사실·숫자·변수·공정을 추가하지 말고, 비율·차이 계산도 하지 말 것	근거 없는 수치 생성

규칙	막으려는 문제
숫자는 소수점까지 적힌 그대로 옮길 것	반올림·오기
'이탈'은 분석 결과가 이탈이라고 한 값에만 쓸 것	정상 값을 이상으로 오인
'이 제품 통과 시 값'과 '현재 운전값(최근 평균)'을 구분할 것	두 값의 혼동
조치·권고는 분석 결과에 조치 항목이 있을 때 그 내용만 전할 것	근거 없는 조치 제안
정상범위를 벗어난 값이 여러 개면 빠짐없이 말하고 "다른 공정은 정상" 같은 일반화를 하지 말 것	이탈 값 누락
분석 결과에 없는 질문은 추가 조사 결과에서 찾고, 없으면 "확인된 자료가 없다"고 말할 것	모르는 내용을 지어냄

이 가운데 숫자, 이탈 값 누락, 지어낸 조치는 2.2 절 4 단계에서 코드로 다시 검사한다. 나머지는 프롬프트 지시에 의존한다.

4.3 LLM 추가 조사 규칙

LLM 이 2.2 절 2 단계에서 도구를 골라 추가 조사할 때는 시스템 프롬프트로 같은 판단 원칙을 준다. 먼저 `get_product_trace` 로 이 제품의 공정값을 확인하고, 최근 동향(SHAP)과 이 제품의 값을 구분해서 말한다. 숫자는 도구 결과에 있는 값만 쓰고, 조정 불가 변수는 상류 통보를 제안하며, 조치는 SOP 근거와 검증을 거친 값만 제안한다. 공정값이 모두 정상이면 단발성·오검출 가능성을 알린다. 등록 도구는 이 단계에 주지 않는다.

5. 안전장치

제조 현장에서 AI 의 잘못된 판단이 바로 설비에 반영되면 큰 사고로 이어질 수 있다. 그래서 안전장치를 두 층으로 나눴다. 프롬프트 규칙은 LLM 이 올바르게 판단하도록 유도하고, 코드 차원의 장치는 LLM 이 규칙을 어겨도 위험한 결과가 나가지 않도록 막는다.

5.1 안전장치 목록

안전장치	막는 위험	구현	층
엔진 우선 판단	소형 LLM 의 잘못된 원인·조치 판단	로컬 LLM 모드에서 원인·조치는 규칙·통계 엔진이 계산, LLM 은 설명만 작성	코드
근거 숫자 검사	LLM 이 근거에 없는 숫자를 만드는 것	LLM 답의 숫자를 엔진 결과·추가 조사 결과와 대조해 하나라도 없으면	코드

안전장치	막는 위험	구현	층
		LLM 답 폐기, 엔진 원문 사용 (한 자리 정수·ID 제외)	
이탈 값 누락 보충	LLM 이 정상범위를 벗어난 값을 빠뜨리는 것	원인·조정 답변에서 빠진 이탈 변수를 엔진이 답 끝에 덧붙이고 "나머지는 정상" 식 문장 삭제	코드
지어낸 조치 제거	근거 없는 조정·권고 문장	엔진이 조치를 내지 않은 답에서 조치·권고 문장 삭제	코드
LLM 쓰기 권한 제한	LLM 이 임의로 조치를 등록하는 것	로컬 LLM 에는 조회 도구만 제공, 등록은 엔진이 작업자 요청 시에만 수행	코드
승인 대기 등록	AI 가 설비를 직접 바꾸는 것	submit_recommendation 은 pending 상태로 저장만 하며, 반영은 작업자 승인 후	코드
등록 전 재검증	검증을 건너뛴 값의 등록	submit_recommendation 이 내부에서 check_adjustment 를 다시 실행해 실패하면 거부	코드
허용 한계·조정폭 검증	설비 한계를 넘거나 한 번에 크게 바꾸는 조정	check_adjustment 가 위반 시 안전값 제시	코드
조정 불가 변수 차단	상류 변수 조정	개재물 지수는 검증 단계에서 즉시 실패, 제강 통보 안내	코드
단발성·오검출 판단	정상 범위 제품을 공정 문제로 오인	원인 후보 값이 정상이면 조정 대신 관찰 권고, 이탈 값도 없고 신뢰도가 낮으면 육안 재검사 권고	코드
표본 부족 경고	적은 데이터로 원인 단정	같은 결함 표본이 10 건 미만이거나 최근 구간에 없으면 SHAP 대신 규칙	코드

안전장치	막는 위험	구현	층
		기반 추정임을 밝힘	
시점 제한	미래 데이터를 보고 판단하는 것	공정·검사 데이터를 조회하는 도구는 선택 제품의 검출 시점까지의 데이터만 사용	코드
Fallback	LLM 장애로 답변이 멈추는 것	호출 실패 시 엔진 결과로 자동 전환	코드
설명 규칙	이탈 오인, 값 혼동 등 숫자 외 오류	설명 프롬프트 규칙(4.2 절)	프롬프트

코드 층의 장치는 LLM 이 규칙을 어겨도 결과에서 걸러낸다. 반면 "이탈"이라는 판단 표현이나 값의 의미처럼 숫자가 아닌 오류는 아직 프롬프트 규칙에만 의존하며, 이 부분의 한계는 6.2 절에서 다룬다.

5.2 실제 차단 사례: 개재물 제품

개재물 고장 구간의 제품 C261003-03412(검출 신뢰도 0.762)를 지정해 오프라인 엔진의 대화 함수(chat)에 "조치안을 승인 대기로 등록해줘"라고 물은 사례다(팀 DB data/factory.db 사본에서 실행). 4·5 단계는 LLM 이 규칙을 어기고 조정 불가 변수를 등록하려는 상황을 재현하려고 같은 도구를 직접 호출했다.

단계	도구	내용	결과
1	get_product_trace	이 제품의 공정값 역추적	슬래브 개재물 지수 1.622 (정상 0.6~1.4) 이탈
2	rank_causes	최근 개재물 결함의 SHAP 원인 순위	개재물 지수 49% > 압하력 10% > 디스케일링 압력 7%
3	엔진 조치 판단	원인 변수가 조정 가능한지 확인	"열연 공정에서 조정할 수 없는 상류 변수 → 해당 LOT 보류, 제강 공정 통보" 제안, 등록하지 않음
4	check_adjustment	개재물 지수 1.0 으로 조정 검증 (직접 호출)	실패: "열연 공정에서 조정 불가(상류 공정 변수) → 제강 공정 통보 필요"
5	submit_recommendation	개재물 지수 1.0 으로 승인 대기 등록 시도 (직접 호출)	등록 거부 (내부 재검증 실패), actions 테이블 변화 없음

작업자가 등록을 요청했지만 엔진은 원인 변수가 조정 불가임을 확인하고, 등록 대신 LOT 보류와 제강 통보를 제안했다. 등록 도구를 직접 호출해도 submit_recommendation 내부에서 check_adjustment 를 다시 실행해 등록을 거부했다. 프롬프트 규칙이 지켜지지 않는 경우에도 설비에 영향을 주는 동작은 코드에서 막힌다는 설계 원칙을 확인한 사례다.

6. 검증 결과

평가는 팀 저장소의 평가 스크립트로 수행했으며, 측정 장비는 Windows 10 PC(RTX 3060)다. 결과 원본은 runs/eval_agent_time_*.json, runs/eval_agent_quality.md, logs/run_*.jsonl 에 있고, 로컬 LLM 응답 시간 3회 측정 기록은 runs/eval_agent_time_runs.md, 답변 품질 사람 검토 기록은 runs/eval_agent_quality_review.md 에 있다.

6.1 응답 시간

scripts/eval_agent_time.py 는 고장 구간에서 불량 판정된 제품을 골라 원인("이 결함은 어느 공정에서 발생했어?").조치("어떻게 조치해야 해?").이력("과거에 비슷한 조치가 있었어?") 세 가지 질문을 각각 새 대화로 묻고, 검증된 조언이 화면에 나올 때까지와 최종 답변이 끝날 때까지의 시간을 잰다. 오프라인 엔진은 제품 10 개, 로컬 LLM 은 제품 4 개로 같은 코드에서 3 회 측정했고, 모델과 SHAP 라이브러리를 불러오는 첫 1 회는 측정에서 뺐다.

모드	측정 건수	검증된 조언 표시	최종 답변 완료	5 초 이내
오프라인 엔진	30 건	평균 0.56 초 (최대 0.73 초)	조언과 동일	30/30
로컬 LLM (Qwen3 8B)	12 건 × 3 회	회차별 평균 0.45 초 이하 (최대 0.70 초)	회차별 평균 11.5~21.1 초 (최대 27.1 초)	조언 36/36, 최종 답 0/36

엔진 결과를 먼저 보여주는 구조 덕분에 작업자는 두 모드 모두 1 초 안에 검증된 조언을 받는다. 로컬 LLM 의 설명이 완성되기까지는 측정 순서대로 회차별 평균 21.1 초, 17.4 초, 11.5 초가 걸렸고, 그동안 작업자는 이미 표시된 조언을 보고 있다. 코드와 설정이 같은데도 회차별 차이가 컸으며 원인은 확인하지 못했다.

6.2 답변 품질

scripts/eval_agent_quality.py 는 불량 제품을 고장 구간 안(실제 공정 문제)과 밖(단발성·오검출)에서 반씩 골라, 원인·조치·이력 세 가지 질문을 각각 새 대화로 묻고 답변의 문제를 자동으로 분류한다. 로컬 LLM 으로 제품 4 개 × 질문 3 개 = 12 건을 측정했다. 이 평가는 10/5 14:53 에 실행했고, agent/chat.py 는 그 뒤 15:53 에 마지막으로 수정했다. 아래 결과는 최종 직전 버전의 답변이며, 최종 버전으로는 다시 평가하지 않았다.

검사 항목	의미	건수
느림	응답 5 초 초과	12
미조치	고장 구간 안 제품인데 조정·관찰 판단 없이 끝남	1

검사 항목	의미	건수
누락 · 모순 · 오조치 · 지시문 노출 · Fallback	이탈 값 누락, 이탈 값을 정상이라고 함, 단발성 제품에 조정 제안 등	0

자동 검사 기준으로는 속도 외의 문제가 1 건(미조치)이었고, 이 1 건도 실제로는 조정값을 제안했으나 검사 형식("→ 값")과 달라 잘못 걸린 것이다. 그러나 12 건의 답변 원문을 직접 확인한 결과, 자동 검사가 잡지 못한 오류가 10 건에 있었다. 건별 판정은 runs/eval_agent_quality_review.md 에 기록했다.

판단 표현 오류(3 건): 정상범위 안의 값을 "벗어났다.이탈"이라고 설명했다. C261001-00381 원인(권취 온도 605.258°C, 정상 595~635), C261005-05688 조치(압하력 18.27MN, 허용 14.0~24.0), C261003-02901 원인(가열 시간 219.945min, 정상 190~230).

값·의미 오류(2 건): C261002-02327 조치에서 권취 온도의 1 회 조정폭을 1.0°C 라고 했다(실제 20°C). C261001-00381 조치에서는 원인 변수가 아닌 다른 변수의 값(2.97mm)과 검증 문구를 섞어 설명했다.

내부 항목 이름 노출(3 건): "[원인 추정]에 명시된 공정", "[조치]는...", "[참고]는..."처럼 엔진 결과의 항목 이름이 답에 그대로 나왔다(C261002-02327·C261001-00381 이력, C261003-02901 조치). 자동 검사는 [분석 결과]·[Agent 추가 조사]만 찾아 걸러지지 않았다.

의미 없는 답(2 건): 이력 질문에 "이탈 값: 개재물, 현재 운전값: 0.835"처럼 항목과 숫자를 엉뚱하게 짝지은 답을 냈다(C261005-05688·C261003-02901 이력).

이 답들은 숫자 자체는 근거에 있는 값이라 근거 숫자 검사를 통과했다. 원인·조치 판단은 엔진이 계산해 LLM 설명보다 먼저 화면에 표시하므로 작업자가 받는 조언 자체는 틀리지 않지만, 8B 모델이 쓴 설명은 그대로 믿기 어려운 수준이다. 판단 표현과 항목 이름을 코드로 검사하는 장치가 필요하다(7 장).

6.3 터미널 조사 모드 (규칙 기반 플래너)

터미널 조사 모드(run_demo.py --scenario <시나리오> --offline)를 규칙 기반 플래너로 두 시나리오에서 실행했다. 실행 기록은 logs/run_20261005_171935.jsonl(스크래치), logs/run_20261005_171938.jsonl(개재물)이다. 플래너가 도구 순서를 정해 두고 실행하므로, 아래 결과는 도구와 검증 로직이 의도대로 동작하는지를 보여준다.

항목	스크래치 시나리오	개재물 시나리오
주입한 원인	출속 속도 높음	개재물 지수 높음 (조정 불가)
급증 탐지	스크래치 6.4% → 16.7% (급증)	개재물 10.9% → 18.0% (2 배 미만, 급증 아님)
찾은 원인	출속 속도 (SHAP 60%, +3.8σ), 2 순위 디스케일링 압력 (SHAP 7%)	급증이 없어 조사 종료
검증 실패 후 재검증	10.0 m/s 제안 → 1 회 최대 조정폭 0.8 m/s 초과로 실패 → 안전값 10.674 로 재검증 통과	해당 없음

항목	스크래치 시나리오	개재물 시나리오
승인 대기 등록	등록	없음
최종 조치	출속 속도 11.474 → 10.674 m/s 1 차 하향	"급중한 결함 유형 없음, 조치 불필요"
전체 소요 시간	1.6 초	0.1 초

스크래치 시나리오에서는 주입한 원인을 찾고, 목표값이 1 회 조정폭을 넘자 검증 도구가 준 안전값으로 다시 검증해 등록했다. 범위 확정서에서 시연 성공조건으로 정한 Feedback 장면이다. 개재물 시나리오(에피소드 7 종료 시점)는 급증으로 잡히지 않아 조사가 첫 단계에서 끝났다. 최근 300 개 중 고장 구간은 137 개뿐이라 발생률이 희석됐고(18.0%), 정상 제품의 개재물 오검출 때문에 기준 구간 발생률도 10.9%로 높아 "기준의 2 배" 조건에 못 미쳤다. 같은 구간의 개재물 제품을 대화에서 지정하면 원인(개재물 지수)과 상류 통보 조치는 정상적으로 나온다(5.2 절).

7. 한계 및 개선 과제

구분	현재 한계	개선 방향
LLM 설명 정확도	숫자는 맞지만 정상 값을 "이탈"이라고 쓰거나 내부 항목 이름을 노출하는 등 표현 오류가 코드 검사를 통과함 (6.2 절, 최종 직전 버전 12 건 중 10 건)	최종 버전으로 재평가, LLM 답의 "이탈·벗어남" 표현이 엔진의 이탈 목록에 있는 변수에만 쓰였는지 검사, 항목 이름 노출 필터 확대, 자동 품질 검사 항목 보강
LLM 설명 시간	로컬 LLM 최종 답변 회차별 평균 11.5~21.1 초로 5 초 안에 끝나지 않고, 측정마다 편차가 큼	조언은 엔진이 1 초 안에 표시하므로 체감 대기는 없음. 설명 길이 축소, 회차별 편차 원인 확인, 더 작은 모델과의 품질·속도 비교
평가 규모	품질 평가 12 건, 응답 시간 오프라인 30 건·로컬 LLM 12 건 × 3 회	결함 6 종 × 구간 안·밖을 고르게 늘려 통계적으로 의미 있는 표본 확보
실행 환경	로컬 LLM 은 GPU 가 있어야 실용적인 속도가 나옴	시연 PC 사양 확인, 필요 시 모델 크기 조정
상류 통보 등록	등록 도구가 조정값만 지원해 조정 불가 변수의 "제강 통보"를 이력으로 남길 방법이 없음	통보·보류 유형 조치를 등록하는 경로 추가
조사 모드	터미널 조사 모드는 규칙 기반 플래너로만 실행했으며, 로컬 LLM 이 도구를 고르는 방식으로는 연결되어 있지 않음	앱 대화와 같은 로컬 LLM 계층으로 통합

구분	현재 한계	개선 방향
급증 기준	고장 구간이 짧거나 기준 구간 오검출이 많으면 급증으로 잡히지 않음 (6.3 절 개재물 시나리오)	비전 오검출 감소, 급증 판단에 공정변수 이탈을 함께 사용
미사용 코드	개발 초기에 만든 Claude API 연결 코드가 남아 있으나 사용. 검증하지 않음	제출본에서 제거하거나 로컬 LLM 계층으로 정리